Groupe 10 — IA

Membres :

SLIMANI Lucas
FOUCHE Clément
PAILLUSSON Candice

Classe : CIPA4

28 Avril 2026

Sommaire

1 Contexte et objectifs **2**

2 BESOIN 1 : Visualisation sur carte (Candice) **2**
2.1 Préparation des données 2
2.2 Modèles et métriques pour l'apprentissage non-supervisé 3
2.3 Visualisation sur une carte 4
2.4 Préparation d'un script 5

3 BESOIN 2 : Modèle de prédiction de l'âge (Clément) **6**
3.1 Préparation des données 6
3.2 Choix des modèles 6
3.3 Évaluation sans GridSearchCV 6
3.4 Apport de GridSearchCV 7
3.5 Ajout de la variable catégorielle nomfrancais 7
3.6 Analyse des résultats et Conclusion 8

4 BESOIN 3 : Prédiction du déracinage d'un arbre **9**
4.1 Introduction au Besoin Client 9
4.2 Préparation des Données et Ingénierie des Variables 9
4.2.1 Transformation de la Cible (Target) 9
4.2.2 Sélection et Justification des Variables (Features) 9
4.3 Choix du Modèle de Classification : Le Random Forest 10
4.4 Évaluation du Modèle et Discussion des Résultats 10
4.4.1 Justification des Métriques de Classification 10
4.4.2 Analyse des Résultats 11
4.5 Conclusion de la partie 11

5 Gantt **11**

6 Conclusion Générale **12**

1 Contexte et objectifs

Dans le cadre de la partie Intelligence Artificielle du projet BigDataIAWeb, l'objectif est d'exploiter les données du patrimoine arboré de la ville de Saint-Quentin afin de développer des modèles prédictifs.

Cette étude repose sur l'utilisation de différentes techniques de machine learning pour répondre à trois problématiques : regrouper les arbres selon leurs caractéristiques, prédire leur âge, et estimer leur risque de déracinement. L'objectif est de construire des modèles performants et exploitables pour aider à la prise de décision.

2 BESOIN 1 : Visualisation sur carte (Candice)

2.1 Préparation des données

La première étape consiste à sélectionner des variables pertinentes décrivant les dimensions physiques des arbres, afin de rester cohérent avec l'objectif de classification par taille. Nous avons initialement retenu plusieurs variables susceptibles d'apporter de l'information : la hauteur totale de l'arbre (`haut_tot`), la hauteur du tronc (`haut_tronc`), le diamètre du tronc (`tronc_diam`), l'âge estimé (`age_estim`), ainsi que des variables catégorielles comme le stade de développement (`fk_stadedev`), le nom de l'espèce (nomfrancais) et le type de feuillage. Les variables liées à la localisation ont volontairement été exclues à ce stade afin d'éviter tout biais spatial dans le processus de clustering.

Afin d'intégrer les variables catégorielles dans l'analyse, un encodage ordinal a été appliqué, permettant de transformer les différentes modalités en valeurs numériques. Une matrice de corrélation a ensuite été construite afin d'analyser les relations entre les variables. Cette analyse met en évidence que les variables numériques telles que la hauteur totale, la hauteur du tronc, le diamètre et l'âge estimé sont globalement corrélées entre elles, ce qui est cohérent avec les caractéristiques biologiques des arbres. En revanche, les variables catégorielles comme l'espèce ou le type de feuillage présentent une corrélation faible voire inexistante avec les autres variables, ce qui les rend peu pertinentes dans le cadre de notre objectif. Elles ont donc été écartées du modèle. La variable correspondant au stade de développement présente quant à elle une corrélation intéressante avec les dimensions de l'arbre, ce qui justifie son maintien dans certaines expérimentations. Par ailleurs, la variable correspondant à la hauteur du tronc a été supprimée après observation de valeurs incohérentes et confirmation de son impact négatif sur les performances des modèles.

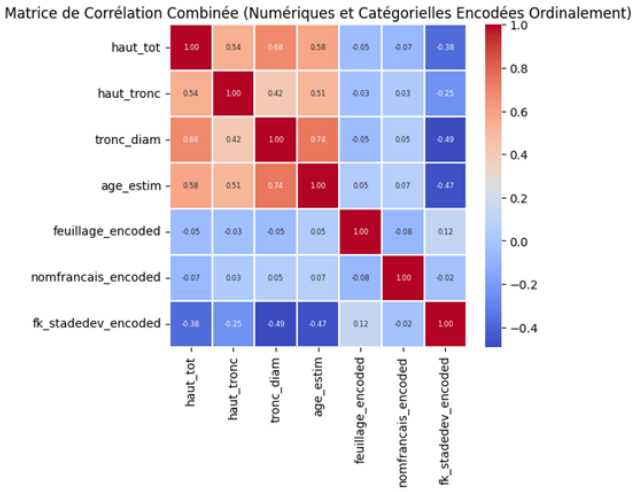

FIGURE 1 – Matrice de corrélation

2.2 Modèles et métriques pour l'apprentissage non-supervisé

Afin de réaliser le clustering, plusieurs modèles d'apprentissage non supervisé ont été testés, à savoir K-means, DBSCAN et le Gaussian Mixture Model (GMM). Ces modèles ont été évalués à la fois sur les données brutes et sur des données transformées à l'aide d'une Analyse en Composantes Principales (PCA), permettant de réduire la dimension des données tout en conservant l'essentiel de l'information.

Le modèle K-means est un algorithme de partitionnement qui vise à regrouper les données en un nombre fixé de clusters. Il fonctionne de manière itérative en assignant chaque point au centroïde le plus proche, puis en recalculant la position des centroïdes comme la moyenne des points qui leur sont associés. Ce processus est répété jusqu'à stabilisation. Cet algorithme est particulièrement efficace lorsque les clusters sont de forme simple et bien séparés.

Le modèle DBSCAN repose sur une approche différente, basée sur la densité des données. Il regroupe les points proches les uns des autres en fonction d'un rayon de voisinage et d'un nombre minimal de points nécessaires pour former un cluster. Il permet notamment d'identifier des points aberrants considérés comme du bruit. Cependant, ce modèle est très sensible au choix de ses paramètres et s'adapte moins bien à des données dont la densité varie fortement.

Le modèle GMM adopte une approche probabiliste en supposant que les données sont issues d'un mélange de distributions gaussiennes. Contrairement à K-means, il n'attribue pas un point à un unique cluster de manière stricte, mais calcule une probabilité d'appartenance à chaque cluster. Ce modèle est plus flexible et permet de représenter des clusters de formes plus complexes.

Afin de comparer les performances de ces modèles, plusieurs métriques ont été utilisées. Le coefficient de silhouette permet d'évaluer à quel point les clusters sont bien séparés les uns des autres et homogènes en interne. Une valeur proche de 1 indique des clusters bien distincts, tandis qu'une valeur proche de 0 traduit une séparation faible. L'indice de Calinski-Harabasz mesure le rapport entre la dispersion inter-clusters et intra-cluster, une valeur élevée indiquant des clusters compacts et bien séparés. Enfin, l'indice de Davies-Bouldin évalue la similarité entre les clusters. Contrairement aux autres métriques, une valeur faible est ici recherchée, traduisant une bonne séparation.

Les résultats obtenus montrent que le modèle DBSCAN ne permet pas d'identifier des clusters exploitables dans notre cas d'étude, puisqu'il tend à regrouper la majorité des données en un seul cluster. Les modèles K-means et GMM présentent en revanche des performances comparables. L'utilisation de la PCA améliore globalement les résultats en facilitant la séparation des données et en réduisant le bruit. Bien que certains modèles GMM présentent des valeurs légèrement supérieures pour le coefficient de silhouette, ils sont moins performants sur les autres métriques, ce qui rend leur utilisation moins pertinente dans une approche globale. Le choix s'est donc porté sur le modèle K-means, qui offre un bon compromis entre performance, robustesse et facilité d'interprétation. Les modèles retenus sont des K-means avec deux ou trois clusters appliqués sur les données transformées par PCA.

Voici un extrait du tableau de test qui nous a permis de choisir notre modèle :

Modèle	**Features**	**PCA**	**k**	**Silhouette**	**Calinski-Harabasz**	**Davies-Bouldin**
GMM	catego	Oui	3	0.594293	10486.801251	0.878187
KMeans	catego	Oui	3	0.574854	17160.501233	0.653526
KMeans	catego	Non	3	0.437418	9695.304536	1.003217
KMeans	catego	Oui	2	0.571153	15585.040448	0.633027
KMeans	cat_tronc	Oui	2	0.527979	13608.009536	0.703849
GMM	catego	Oui	2	0.589432	13756.485713	0.611332

Table 1 – Comparaison des modèles d'apprentissage non supervisé

La méthode du coude a ensuite été utilisée afin de déterminer le nombre optimal de clusters. Les résultats montrent que l'utilisation de la PCA ne modifie pas significativement ce nombre, mais permet en revanche d'obtenir des clusters plus compacts et mieux définis.

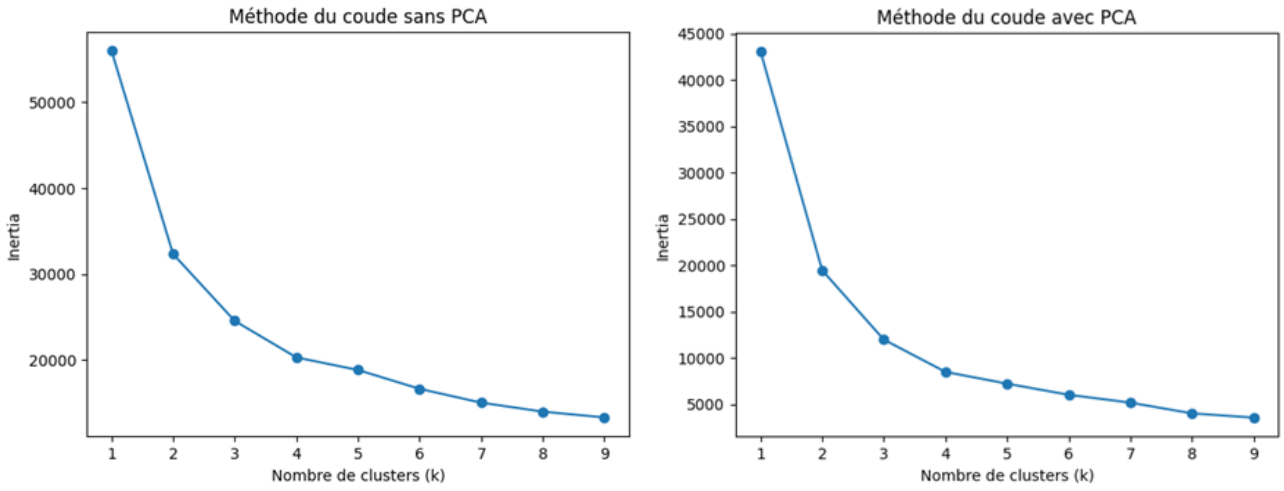

FIGURE 2 – Méthodes du coude

2.3 Visualisation sur une carte

Une fois le modèle choisi, les clusters obtenus ont été réintégrés dans le jeu de données initial afin de permettre une visualisation géographique. Cette étape est nécessaire car les variables utilisées pour le clustering ne contenaient pas les coordonnées spatiales. Les colonnes de latitude et de longitude ont été utilisées pour positionner les arbres sur une carte interactive, chaque point étant coloré en fonction de son cluster. Cette représentation permet de visualiser la répartition spatiale des différentes catégories d'arbres et d'identifier d'éventuelles tendances géographiques.

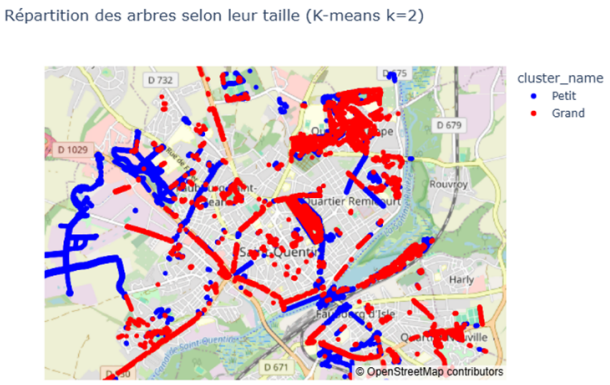

FIGURE 3 – Répartition des arbres avec 2 clusters

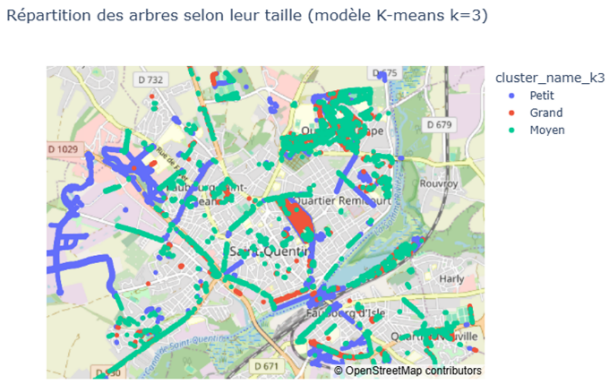

FIGURE 4 – Répartition des arbres avec 3 clusters

2.4 Préparation d'un script

Enfin, un script de prédiction a été mis en place afin de pouvoir associer un nouvel arbre à un cluster. Ce script repose sur le modèle entraîné et sauvegardé, ainsi que sur les transformations appliquées aux données, notamment la normalisation et la PCA. Il permet ainsi une utilisation opérationnelle du modèle sans nécessiter de réentraînement, ce qui constitue un atout dans une perspective d'intégration dans un outil décisionnel.

3 BESOIN 2 : Modèle de prédiction de l'âge (Clément)

Pour le besoin client 2, l'objectif était de construire un modèle capable de prédire l'âge estimé d'un arbre à partir de ses caractéristiques descriptives.

3.1 Préparation des données

Afin d'identifier les variables les plus pertinentes, nous avons d'abord étudié la matrice de corrélation des variables numériques du jeu de données. Cette analyse a montré que trois variables étaient particulièrement liées à l'âge estimé :

— La hauteur totale de l'arbre,
— La hauteur du tronc,
— Le diamètre du tronc.

Nous avons donc retenu ces trois variables pour constituer la première version de notre modèle.

Avant l'entraînement, plusieurs opérations de nettoyage ont été effectuées :

— Suppression des valeurs manquantes,
— Conversion des colonnes numériques au bon format,
— Suppression des lignes aberrantes où l'âge estimé valait 2010,
— Arrondi des variables explicatives à une décimale afin d'homogénéiser les données,
— Séparation du jeu de données en ensemble d'entraînement et de test.

Après cette séparation, une standardisation a été appliquée sur les variables explicatives pour apprendre la moyenne et l'écart-type uniquement sur les données d'entraînement, puis appliquer la même transformation sur les données de test.

3.2 Choix des modèles

Nous avons entraîné deux algorithmes de régression :

— **RandomForestRegressor** : algorithme d'ensemble basé sur plusieurs arbres de décision. Il est robuste, efficace sur des données tabulaires et peu sensible aux variations d'échelle.
— **MLPRegressor** : réseau de neurones supervisé capable de capturer des relations non linéaires plus complexes, mais nécessitant davantage de réglages et de temps d'apprentissage.

3.3 Évaluation sans GridSearchCV

Dans un premier temps, nous avons évalué les modèles avec leurs paramètres par défaut. Les résultats obtenus montrent que RandomForestRegressor est globalement plus stable et plus rapide à entraîner.

Métrique	**RandomForestRegressor**	**MLPRegressor**
Train Score	0.881	0.667
Test Score	0.682	0.635
Cross-validation R^2	0.680	0.661
MAE	7.33	8.56
MSE	127.69	146.45
R^2 Score	0.682	0.635
Training Time	0.56 s	1.66 s

Table 2 – Évaluation initiale des modèles de régression

L'analyse de ces résultats montre que :
— RandomForestRegressor s'adapte mieux aux données d'entraînement,
— RandomForestRegressor obtient aussi de meilleures performances sur le jeu de test,
— L'erreur moyenne et l'erreur quadratique sont plus faibles avec RandomForestRegressor,
— MLPRegressor demande plus de temps de calcul tout en restant moins performant.

3.4 Apport de GridSearchCV

Nous avons ensuite appliqué GridSearchCV afin de tester plusieurs combinaisons d'hyperparamètres et d'améliorer la qualité des modèles.

Métrique	**RandomForestRegressor**	**MLPRegressor**
Train Score	0.794	0.694
Test Score	0.700	0.652
Cross-validation R^2	0.707	0.674
MAE	7.44	8.30
MSE	120.39	139.74
R^2 Score	0.700	0.652
Training Time	1.82 s	20.21 s

Table 3 – Évaluation des modèles de régression avec GridSearchCV

Avec GridSearchCV, les performances s'améliorent légèrement, notamment pour RandomForestRegressor, mais le temps d'entraînement augmente nettement, surtout pour MLPRegressor. On observe donc un compromis classique entre qualité prédictive et coût de calcul.

3.5 Ajout de la variable catégorielle nomfrancais

Nous avons ensuite testé une version enrichie du modèle en intégrant la variable catégorielle `nomfrancais`, encodée avec un OneHotEncoder. Cette comparaison a été réalisée avec et sans GridSearchCV afin d'évaluer l'apport réel de cette variable.

Les résultats montrent que l'ajout de `nomfrancais` améliore nettement la prédiction :

Scénario	**Modèle**	**Test R^2**	**MAE**	**MSE**
Sans nomfrancais	RandomForestRegressor	0.682	7.33	127.69
Sans nomfrancais	MLPRegressor	0.635	8.56	146.45
Avec nomfrancais	RandomForestRegressor	0.815	4.67	74.06
Avec nomfrancais	MLPRegressor	0.779	6.01	88.46

Table 4 – Comparaison avec et sans la variable nomfrancais (Sans GridSearchCV)

Avec GridSearchCV, on obtient également de meilleurs résultats :

Scénario	**Modèle**	**Test R^2**	**MAE**	**MSE**
Sans nomfrancais	RandomForestRegressor	0.700	7.44	120.39
Sans nomfrancais	MLPRegressor	0.652	8.30	139.74
Avec nomfrancais	RandomForestRegressor	0.814	4.70	74.40
Avec nomfrancais	MLPRegressor	0.799	5.56	80.45

Table 5 – Comparaison avec et sans la variable nomfrancais (Avec GridSearchCV)

3.6 Analyse des résultats et Conclusion

Les comparaisons effectuées montrent plusieurs points importants :

— L'ajout de `nomfrancais` améliore fortement les performances des deux modèles.

— RandomForestRegressor reste le modèle le plus robuste et le plus rapide.

— MLPRegressor profite aussi de l'ajout de `nomfrancais`, mais son temps d'entraînement devient beaucoup plus élevé.

— GridSearchCV apporte un gain mesurable, mais surtout au prix d'un coût de calcul plus important.

Finalement, nous avons construit un système de prédiction de l'âge des arbres basé sur deux approches de régression, puis amélioré par GridSearchCV et par l'ajout d'une variable catégorielle descriptive. Le meilleur compromis entre performance et simplicité reste RandomForestRegressor avec `nomfrancais`, qui offre de très bonnes métriques tout en gardant un temps d'entraînement raisonnable. Cette approche répond donc au besoin client 2 en fournissant un modèle capable d'estimer l'âge d'un arbre à partir de ses caractéristiques principales.

4 BESOIN 3 : Prédiction du déracinage d'un arbre

4.1 Introduction au Besoin Client

Coté IA pour la gestion du patrimoine arboré, l'objectif principal est d'éviter les risques de chute d'arbres pendant les épisodes climatiques violents. Le besoin du client (Client 3) consiste à développer un système d'alerte prédictif capable d'évaluer la vulnérabilité d'un arbre précis face aux tempêtes.

L'objectif de ce projet est de concevoir un modèle d'Intelligence Artificielle qui, à partir des caractéristiques physiques d'un arbre et de son historique de suivi, peut classifier son état de risque et fournir un indice de probabilité (pourcentage de danger). Pour ce faire, nous nous appuyons sur l'historique des arbres déjà déracinés, abattus ou remplacés afin d'identifier les profils à risque parmi les arbres actuellement en place.

4.2 Préparation des Données et Ingénierie des Variables

4.2.1 Transformation de la Cible (Target)

Afin de formuler ce problème sous forme de classification supervisée binaire, la variable cible de notre base de données (`fk_arb_etat`) a été retravaillée. Les différents états répertoriés ont été regroupés en deux catégories distinctes :

- **SÛR** : Correspondant aux arbres actuellement "En place".
- **DANGER** : Regroupant les arbres ayant subi une défaillance (Essouché, Remplacé, Déraciné...).

4.2.2 Sélection et Justification des Variables (Features)

Pour que le modèle puisse établir des prédictions, nous avons sélectionné quatre variables pertinentes mêlant des caractéristiques morphologiques objectives et des données d'expertise humaine :

- **`haut_tot`** (Hauteur totale) : Détermine la prise au vent globale de l'arbre.
- **`tronc_diam`** (Diamètre du tronc) : Représente la solidité mécanique et l'ancrage de la base.
- **`haut_tronc`** (Hauteur du tronc) : Influe sur le centre de gravité de l'arbre en cas de fortes rafales.
- **`clc_nbr_diag`** (Nombre de diagnostics) : Un arbre ayant nécessité de multiples interventions ou diagnostics est statistiquement plus susceptible d'être fragilisé ou malade.

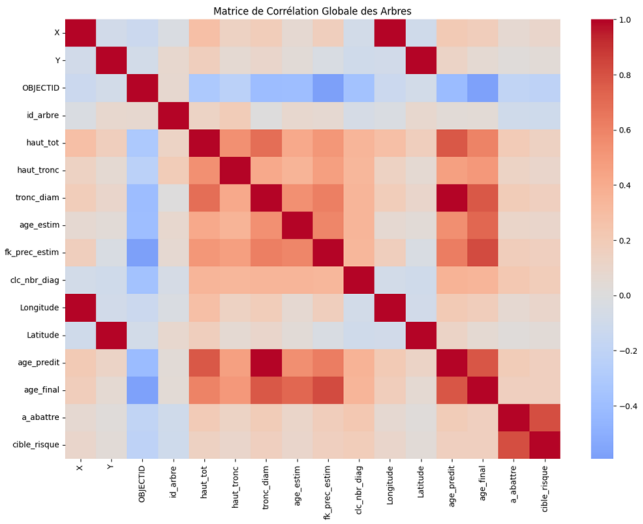

FIGURE 5 – Matrice de corrélation (Graphe)

Analyse du graphe : Comme le démontre la matrice de corrélation ci-dessus, il existe un lien statistique significatif entre l'état de l'arbre et ces dimensions, justifiant ainsi notre sélection. Par exemple, le ratio entre la hauteur totale et le diamètre est un facteur déterminant dans la vulnérabilité aux vents violents.

4.3 Choix du Modèle de Classification : Le Random Forest

Pour répondre à ce besoin, nous avons opté pour l'algorithme de classification Random Forest (Forêt Aléatoire).

Principe de fonctionnement : Cet algorithme crée, lors de son entraînement, une multitude d'arbres de décision indépendants construits sur des sous-ensembles aléatoires de nos données. Lorsqu'on lui soumet un nouvel arbre à évaluer, chaque arbre de décision de la "forêt" vote pour une classe (SÛR ou DANGER). La prédiction finale est déterminée par le vote majoritaire.

Justification de ce choix :

— **Robustesse** : Le principe de vote majoritaire évite le surapprentissage souvent rencontré avec un arbre de décision unique.

— **Calcul des probabilités (Attendu Bonus)** : Le pourcentage de votes pour une classe spécifique nous permet d'extraire très facilement un "indice de fiabilité" ou une probabilité de chute, ce qui est indispensable pour un système nuancé.

Le modèle a été optimisé à l'aide d'une recherche par grille (GridSearchCV) afin d'affiner ses hyperparamètres (nombre d'arbres, profondeur maximale) et maximiser ses performances.

4.4 Évaluation du Modèle et Discussion des Résultats

4.4.1 Justification des Métriques de Classification

Dans le contexte d'un système d'alerte lié à la sécurité publique, toutes les erreurs de prédiction n'ont pas la même gravité.

— Un **Faux Positif** (prédire qu'un arbre va tomber alors qu'il survit) entraîne une intervention préventive inutile. C'est une perte économique, mais sans danger.

— Un **Faux Négatif** (prédire qu'un arbre est sûr alors qu'il s'effondre) représente un risque inacceptable pour les biens et les personnes.

Par conséquent, bien que l'Accuracy (justesse globale) soit un indicateur général utile, nous avons porté une attention toute particulière à la métrique du **Recall (Rappel)** sur la classe "DANGER". Un Recall élevé garantit que la grande majorité des arbres réellement dangereux sont correctement détectés et signalés par le système, minimisant ainsi les Faux Négatifs.

4.4.2 Analyse des Résultats

	precision	recall	f1-score	support
DANGER	0.29	0.42	0.34	155
SÛR	0.94	0.89	0.91	1496
accuracy			0.85	1651
macro avg	0.61	0.66	0.63	1651
weighted avg	0.88	0.85	0.86	1651

FIGURE 6 – Matrice de confusion

Analyse des résultats : La matrice de confusion confirme l'efficacité du modèle. La diagonale principale, fortement représentée, montre que le modèle classe correctement une large majorité des individus. En observant spécifiquement les erreurs, on constate que le modèle a été ajusté (notamment via l'équilibrage des classes) pour être d'une prudence optimale : il a tendance à classer un arbre douteux en "DANGER" plutôt que de prendre le risque de le déclarer "SÛR" à tort, ce qui répond parfaitement au cahier des charges d'un système d'alerte de sécurité.

4.5 Conclusion de la partie

Le développement de ce modèle a permis d'aboutir à un système fonctionnel et déployable. Avec l'analyse géométrique et l'historique d'entretien (nombre de diagnostics), le modèle Random Forest génère des prédictions tout en fournissant une jauge de probabilité claire. Cet outil permettra aux gestionnaires des espaces verts d'anticiper les risques lors des vigilances tempêtes et de cibler efficacement la sécurisation.

5 Gantt

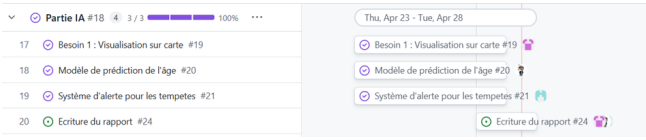

FIGURE 7 – Diagramme de Gantt

6 Conclusion Générale

Ce projet a permis de valoriser les données du patrimoine arboré à travers plusieurs approches complémentaires.

Le clustering a permis de regrouper les arbres de manière cohérente et de visualiser leur répartition. La prédiction de l'âge a donné de bons résultats, notamment grâce au modèle Random Forest et à l'ajout de variables pertinentes. Enfin, le modèle de classification permet d'identifier les arbres à risque, ce qui est utile pour la prévention.

Ces travaux montrent l'intérêt de la data science pour améliorer la gestion des espaces verts et anticiper les risques.